

2025 2학기 공간정보 인공지능 프로젝트 보고서

손승우

1. 개요

1.1 연구 배경 및 필요성

- 농업 생산량은 기후 조건, 토양 수분, 작물 생육 환경 등 다양한 환경 요인의 영향을 받는다. 특히 옥수수는 생육 기간 동안 강수량, 기온, 식생 상태 변화에 민감하여 정확한 수확량 예측을 위해서는 다변량 자료를 고려한 분석이 필요하다. 최근 위성 원격탐사 및 기상·토양 자료의 축적으로 기계학습 기반 회귀 모델을 활용한 농업 생산량 예측이 가능해졌으며, 본 연구에서는 이러한 자료를 이용해 county 단위 옥수수 수확량을 예측하고 그 적용 가능성을 분석하고자 한다.

1.2 연구 목적

- 본 프로젝트의 목적은 위성 식생 지수, 기상 자료 및 토양 수분 자료를 입력 변수로 활용하여 미국 Corn Belt 일부 지역의 county 단위 옥수수 수확량을 예측하는 것이다. 이를 위해 2015년부터 2017년까지의 자료를 학습 데이터로, 2018년 자료를 테스트 데이터로 사용하여 다양한 회귀 모델을 적용하고 예측 성능을 비교함으로써 최적의 예측 모델을 도출한다. 또한 모델 결과를 바탕으로 입력 변수의 중요도를 분석하여, 특정 시기 및 환경 요인이 옥수수 수확량에 미치는 영향을 해석하는 것을 목표로 한다.

2. 회귀 모델

2.1. 사용 자료

- 본 연구에서는 미국 Corn Belt 일부 지역을 대상으로 한 county 단위 옥수수 수확량 예측을 위해 Regression_Corn.csv 자료를 사용하였다. 해당 자료는 USDA-NASS에서 제공한 CONUS 기반 데이터로, 위성 원격탐사 자료와 기상·토양 정보를 결합한 시계열 특성을 갖는다. 분석 대상 기간은 2015년부터 2018년까지이며, 이 중 2015년부터 2017년까지의 자료는 모델 학습을 위한 training data로, 2018년 자료는 예측 성능 평가를 위한 test data로 사용하였다.

- 반응 변수는 연도별 county 단위 옥수수 수확량(yield)으로, 단위는 ton/ha이다. 설명 변수는 총 43개 변수 중 분석에 직접 활용되지 않는 county 식별자(county_id)를 제외한 41개 변수를 사용하였다. 이들 변수는 작물 생육 기간인 4월부터 10월까지의 월별 위성 및 기상 관측값으로 구성되어 있다.

- 위성 식생 지표로는 MODIS 기반 Enhanced Vegetation Index(EVI)가 사용되었으며, 연

도별 16일 합성 자료를 바탕으로 총 13개의 시계열 변수가 포함되어 있다. 기상 요인으로는 월별 누적 강수량(PRCP)과 월 최고 기온(TMAX)이 각각 7개 변수로 제공되며, 토양 수분 상태를 나타내는 SMAP 기반 월 평균 토양 수분(SM) 자료 역시 7개 변수로 구성되어 있다. 또한 식생의 구조적 특성을 반영하는 Vegetation Optical Depth(VOD) 자료가 월 평균 값 기준으로 7개 변수 포함되어 있다.

- 이와 같이 본 연구에서 사용한 자료는 위성, 기상, 토양 정보를 통합한 다차원 시계열 데이터로 구성되어 있으며, 옥수수 수확량과 환경 요인 간의 관계를 기계학습 기반 회귀 모델을 통해 분석하는 데 적합한 특성을 지닌다.

2.2. 회귀 모델

본 연구에서는 연속형 반응 변수인 옥수수 수확량을 예측하기 위해 다양한 회귀 모델을 적용하였다. 회귀 분석은 독립변수와 종속변수 간의 함수적 관계를 학습하여, 새로운 입력 자료에 대한 연속값 예측을 수행하는 기법이다. 본 절에서는 본 연구에서 사용한 주요 회귀 모델들과 이론적 배경을 간략히 설명한다.

- 선형 회귀

선형 회귀 모델은 독립변수들의 선형 결합을 통해 종속변수를 설명하는 가장 기본적인 회귀 기법이다. 다변량 선형 회귀의 경우, 종속변수는 여러 독립변수에 대한 가중합과 절편으로 표현되며, 회귀계수는 최소제곱법을 통해 추정된다. 선형 회귀는 해석이 용이하다는 장점이 있으나, 독립변수 간 상관성이 높은 경우 다중공선성 문제로 인해 회귀계수가 불안정해질 수 있다.

- 정규화(regularization)

회귀 모델에서 회귀계수의 크기를 제한하는 제약 항을 손실 함수에 추가하여 모델의 복잡도를 줄이고 과적합을 방지하는 기법이다. Ridge LASSO 등의 기법이 존재한다.

- Ridge 회귀

이는 선형 회귀에 정규화를 도입한 모델로, 회귀계수의 크기에 대한 ℓ_2 노름 패널티를 손실 함수에 추가한다. 이를 통해 회귀계수의 크기를 제한함으로써 과적합을 방지할 수 있다. Ridge 회귀는 모든 변수를 유지하면서 계수를 축소하는 특징을 가지며, 정규화 강도는 하이퍼파라미터 λ 에 의해 조절된다.

- LASSO 회귀

이는 ℓ_1 노름 기반 정규화를 사용하는 회귀 모델로, 일부 회귀계수를 정확히 0으로 만드는 특성을 가진다. 이로 인해 변수 선택 효과를 제공하며, 고차원 자료에서 불필요한 변수를 제거하는 데 유용하다. 그러나 상관성이 높은 변수들이 존재할 경우, 임의의 하나만 선택되는 경향이 있어 해석 시 주의가 필요하다.


- PCA 주성분 분석

주성분 분석(PCA)을 통해 서로 직교하는 새로운 변수 공간으로 변환한 후, 선택된 주성분을 이용하여 회귀를 수행하는 방법이다. 이를 통해 변수 간 상관성을 제거하고 차원을 축소함으로써 다중공선성 문제를 효과적으로 완화할 수 있다. 다만, 주성분은 종속변수와 의 관계를 고려하지 않고 정의되므로 해석력 측면에서는 한계가 존재한다.


2.3. 자료 처리 절차

- 데이터 분석


회귀 분석에 앞서 입력 자료의 특성과 문제점을 파악하기 위해 다중공선성, 이상치, 변수 스케일 분포에 대한 사전 진단을 수행하였다. 먼저 분산팽창계수(VIF)를 이용해 다중공선성을 확인한 결과, 일부 기온 변수(TMAX 계열)의 VIF 값이 수천 단위까지 나타났으며, 식생 지수(EVI) 변수 또한 높은 VIF 값을 보였다. 이는 월별로 유사한 기상·식생 정보가 반복적으로 포함되어 있어 입력 변수 간 강한 상관관계가 존재함을 의미한다.




또한 입력 변수 간 상관계수 분석 결과, EVI 및 TMAX 계열 변수들 사이에서 $|r| \geq 0.9$ 이상의 매우 높은 상관성을 갖는 변수 쌍이 다수 확인되었다. 이러한 결과는 다중공선성으로 인해 회귀 계수의 불안정성과 예측 성능 저하가 발생할 가능성이 있음을 시사한다.



이상치 분석을 위해 3-sigma 기준을 적용한 결과, 다수의 EVI, 강수량(PRCP), 기온(TMAX) 변수에서 평균으로부터 크게 벗어난 값들이 관측되었다. 특히 특정 월의 식생 지수 및 강수량 변수에서 상대적으로 많은 이상치가 확인되어, 데이터 분포의 왜곡 가능성이 존재함을 확인하였다.



마지막으로 변수 스케일을 확인한 결과, 식생 지수(EVI)와 토양 수분(SM) 변수는 01 범위의 값을 갖는 반면, 강수량(PRCP)은 수십에서 수백 단위, 기온(TMAX)은 1030°C 범위로 나타나 변수 간 스케일 차이가 매우 큰 것으로 확인되었다. 이러한 스케일 차이는 회귀 분석 시 특정 변수의 영향력이 과도하게 반영될 가능성을 내포한다.



종합적으로, 입력 자료는 다중공선성, 이상치 존재, 변수 스케일 불균형 등의 문제를 동시에 포함하고 있어, 신뢰성 있는 회귀 분석을 위해 이상치 제거, 표준화, 차원 축소(PCA), 정규화 기법의 적용이 필요하다고 판단하였다.

- 이상치 제거

이상치 제거는 3-sigma 기준을 적용하되, 단일 변수의 극단값으로 인한 과도한 데이터 손실을 방지하기 위해 두 개 이상의 변수에서 동시에 기준을 초과한 경우에만 이상치로 판단하였다. 해당 기준을 통해 전체 학습 데이터 중 일부 샘플만을 제거하여 데이터의 대표성을 유지하였다.

```
# ===== 이상치 제거 (3-Sigma, train만) =====

train_all = pd.concat([X_train, y_train], axis=1)

z_scores = np.abs((train_all - train_all.mean()) / train_all.std())

outlier_mask = (z_scores > 3).sum(axis=1) >= 2

train_all = train_all.loc[~outlier_mask]

# 다시 분리 (뗄어쓰기)

X_train = train_all.drop(columns=['yield'])

y_train = train_all['yield']

print("After outlier removal:", X_train.shape)


print("Removed samples:", outlier_mask.sum())
```

- 표준화

표준화는 학습 데이터의 평균과 표준편차를 기준으로 각 입력 변수를 평균 0, 분산 1의 분포로 변환하는 방식으로 수행하였으며, 해당 기준은 테스트 데이터에도 동일하게 적용하였다. 이를 통해 변수 단위 차이에 따른 영향력을 제거하고, PCA 및 정규화 회귀 모델이 공정하게 학습될 수 있도록 하였다.

```
# ===== 표준화 =====  
  
scaler = StandardScaler()  
  
X_tr = scaler.fit_transform(X_tr)  
  
X_te = scaler.transform(X_te)
```

- PCA



PCA 적용 시 주성분 개수는 고정된 기준을 사용하는 대신, 누적 분산 설명력 0.90부터 0.99까지의 범위를 대상으로 PCR(Principal Component Regression) 모델의 교차검증 RMSE를 비교하여 결정하였다. 그 결과, 누적 분산 설명력 0.98 수준에서 가장 낮은 RMSE가 나타났으며, 이는 정보 손실과 노이즈 증가 사이의 균형이 가장 적절한 지점으로 판단되었다. 이에 따라 이후 분석에서는 PCA 누적 분산 설명력 0.98을 기준으로 차원을 고정하여 회귀 모델을 적용하였다.

```
pca = PCA(n_components=0.95)  
  
X_tr_final = pca.fit_transform(X_tr)  
  
X_te_final = pca.transform(X_te)
```

- 최종 모델 `run_model` 함수 구성 및 동작 설명

```
def run_model(X_train, y_train, X_test, y_test,  
  
              use_pca=True,  
  
              model_type='linear'):
```

최종 모델인 `run_model` 함수는 PCA 적용 여부 설정, 회귀 모델 학습, 성능 평가, 변수 기여도 분석을 하나의 함수로 통합하여 수행하도록 설계되었다. 이를 통해 PCA 적용 전·후 및 서로 다른 회귀 모델의 성능을 동일한 조건에서 비교할 수 있도록 하였다.

1. PCA 적용 여부에 따른 입력 데이터 구성

```
# ===== PCA =====  
  
    if use_pca:  
        pca = PCA(n_components=0.98)  
        X_tr_final = pca.fit_transform(X_tr)  
        X_te_final = pca.transform(X_te)  
  
    else:  
        X_tr_final = X_tr  
        X_te_final = X_te  
        pca = None
```

`use_pca` 인자에 따라 PCA 적용 여부를 결정한다. PCA를 적용하는 경우, 누적 분산 설명력 0.98 기준으로 주성분을 선택하여 차원 축소를 수행하고, PCA를 적용하지 않는 경우에는 표준화된 원본 변수를 그대로 사용한다. 이를 통해 차원 축소 효과가 모델 성능에 미치는 영향을 직접 비교할 수 있도록 하였다.

2. 회귀 모델 선택 및 학습

```
# ===== 모델 =====

if model_type == 'linear':

    model = LinearRegression()

    model.fit(X_tr_final, y_train)

elif model_type == 'ridge':

    grid = GridSearchCV(

        Ridge(),

        {'alpha': [0.01, 0.1, 1, 10, 100]},

        cv=5, scoring='neg_mean_squared_error'

    )

    grid.fit(X_tr_final, y_train)

    model = grid.best_estimator_

elif model_type == 'lasso':

    grid = GridSearchCV(

        Lasso(max_iter=10000),

        {'alpha': [0.001, 0.01, 0.1, 1]},

        cv=5, scoring='neg_mean_squared_error'

    )

    grid.fit(X_tr_final, y_train)

    model = grid.best_estimator_

else:

    raise ValueError("Invalid model type")
```

model_type 인자에 따라 선형 회귀, Ridge 회귀, LASSO 회귀 중 하나를 선택한다.

- 선형 회귀는 하이퍼파라미터가 없는 기준 모델로 사용된다.
- Ridge와 LASSO의 경우 정규화 강도(α)를 하이퍼파라미터로 설정하고, 교차검증 기반 Grid Search를 통해 최적 값을 탐색한 뒤 모델을 학습한다.

3. 모델 예측 및 성능 평가

```
# ===== 평가 =====

def evaluate(y_true, y_pred):

    mae = mean_absolute_error(y_true, y_pred)

    rmse = np.sqrt(mean_squared_error(y_true, y_pred))

    r = np.corrcoef(y_true, y_pred)[0, 1]

    return mae, rmse, r

def plot_scatter(y_true, y_pred, title):

    plt.figure(figsize=(5, 5))

    plt.scatter(y_true, y_pred, s=10, alpha=0.5)

    plt.plot([y_true.min(), y_true.max()],

             [y_true.min(), y_true.max()],

             'r--')

    plt.xlabel("Observed yield")

    plt.ylabel("Predicted yield")

    plt.title(title)

    plt.grid(True)

    plt.show()

y_pred = model.predict(X_te_final)

mae, rmse, cc = evaluate(y_test, y_pred)

title = f"{model_type.upper()} | PCA={use_pca}"

print(f"\n{title}")

print(f"MAE={mae:.3f}, RMSE={rmse:.3f}, CC={cc:.3f}")

plot_scatter(y_test, y_pred, title)
```

학습된 모델을 이용해 테스트 데이터의 수확량을 예측하고, MAE, RMSE, 상관계수를 계산하여 예측 성능을 정량적으로 평가한다. 또한 실제값과 예측값 간의 관계를 시각적으로 확인하기 위해 산점도를 함께 출력한다.

4. 변수 기여도 분석

```
# ===== 변수 기여도 =====

print("\n[Feature Importance]")

if not use_pca:

    # 원 변수 기준

    importance = pd.Series(

        np.abs(model.coef_),

        index=X_train.columns

    ).sort_values(ascending=False)

    print("Top 10 input features:")

    print(importance.head(10))

else:

    # (1) PC 중요도

    pc_importance = (

        np.abs(model.coef_) *

        pca.explained_variance_ratio_

    )

    pc_series = pd.Series(

        pc_importance,

        index=[f"PC{i+1}" for i in range(len(pc_importance))]

    ).sort_values(ascending=False)

    print("Top PCs:")

    print(pc_series.head(5))

    # (2) 원 변수로 환산한 기여도

    feature_importance = np.dot(
```

```

        np.abs(model.coef_),

        np.abs(pca.components_)

    )

    feature_importance = pd.Series(

        feature_importance,

        index=X_train.columns

    ).sort_values(ascending=False)

    print("\nTop original features:")

    print(feature_importance.head(10))

# ===== 결과 반환 =====

return {

    "PCA": "Yes" if use_pca else "No",

    "Model": model_type.capitalize(),

    "MAE": mae,

    "RMSE": rmse,

    "CC": cc

}

```

모델 해석을 위해 PCA 적용 여부에 따라 서로 다른 방식으로 변수 기여도를 산출한다.

- PCA를 적용하지 않은 경우에는 회귀계수의 절댓값을 이용해 원 변수 기준의 기여도를 계산한다.
- PCA를 적용한 경우에는 주성분 회귀계수와 분산 설명력을 결합해 주성분 중요도를 산출한 뒤, 주성분 적재량을 이용해 이를 원 변수 기준의 기여도로 환산한다.

2.4 결과

	PCA	MODEL	MAE	RMSE	Correlation Coefficient
1	No	Linear	1.123246	1.484899	0.728997
2	No	Ridge	0.941063	1.308132	0.794583
3	No	Lasso	0.957074	1.302171	0.792289
4	Yes	Linear	0.912114	1.255268	0.802130
5	Yes	Ridge	0.908706	1.266016	0.808409
6	Yes	Lasso	0.939013	1.305886	0.798578


본 연구에서 사용한 옥수수 수확량(yield) 자료는 평균 7.66, 표준편차 1.58의 분포를 가지며, 최소 3.00에서 최대 12.35까지 비교적 넓은 변동 폭을 보인다. 이는 county 단위 수확량이 지역적·환경적 요인에 따라 상당한 불확실성을 내포하고 있음을 의미한다.

이러한 분포를 고려할 때, 본 연구에서 적용한 회귀 모델들은 MAE 기준 약 0.91 ~ 1.12의 예측 오차를 보였으며, 이는 평균 수확량 대비 약 12.15% 수준의 평균 절대 오차에 해당한다. 즉, 모델은 county 단위 수확량을 평균적으로 약 1 단위 내외의 오차로 예측하고 있음을 의미한다.


RMSE는 약 1.25~1.48 범위로 나타났으며, 이는 수확량의 표준편차(1.58)보다 약간 작은 수준이다. 이는 일부 오차가 존재함을 시사하지만, 평균값만을 예측하는 단순 기준 모델 대비 예측 성능이 개선되었음을 의미한다. 특히 환경 변수만을 입력으로 사용한 점을 고려할 때, 모델이 수확량 변동의 일부 구조를 유의미하게 학습한 것으로 판단된다.

또한 모든 모델에서 상관계수는 0.72~0.81 범위로 나타나, 수확량의 절대값 예측 정확도는 제한적일 수 있으나 연도 및 지역에 따른 상대적 증감 추세는 비교적 안정적으로 재현하고 있음을 확인하였다.

종합적으로 볼 때, 본 연구에서 적용한 회귀 모델들은 county 단위 옥수수 수확량 예측이라는 복잡한 문제에서 환경 자료 기반 접근만으로도 일정 수준의 예측 성취도를 달성하였다고 판단하였다.




-Scatter plot 결과



산점도 분석 결과, PCA를 적용하지 않은 선형 회귀 모델은 예측값의 분산이 가장 크게 나타나며, 실제 수확량 대비 예측값이 평균 쪽으로 수렴하는 경향이 뚜렷하다. 반면 Ridge 및 Lasso 회귀 모델은 정규화 효과로 인해 분산이 다소 감소하고, 1:1 기준선에 대한 정렬도가 개선된 모습을 보인다.

PCA를 적용한 이후에는 모든 모델에서 예측값이 기준선 주변에 보다 밀집되며, 특히 선형 회귀 모델에서 개선 효과가 가장 크게 나타난다. PCA 적용 Ridge 회귀 모델은 전반적인 분산과 편향이 가장 균형 잡힌 형태를 보이며, 중간 수확량 구간에서 안정적인 예측 성능을 나타낸다.

그러나 모델 종류와 PCA 적용 여부와 관계없이, 고수확량 구간에서는 예측값이 실제값보다 낮게 추정되는 경향이 공통적으로 관찰된다. 이는 선형 기반 회귀 모델의 구조적 한계 및 환경 변수만으로는 극단적인 수확량 변동을 충분히 설명하기 어렵기 때문으로 판단된다.



- 최적 모델 선정 및 세부 결과 해석

본 연구의 성능 비교 결과, PCA를 적용한 선형 회귀 모델이 가장 낮은 RMSE를 기록하였다. 이는 모델 자체의 우수성이라기보다는, 전처리 단계에서 데이터 구조가 효과적으로 정리된 결과로 해석할 수 있다.

PCA 적용 이전에는 입력 변수 간 강한 다중공선성으로 인해 선형 회귀 모델의 성능이 상대적으로 낮았으며, 이 경우 Ridge 및 LASSO 회귀와 같은 정규화 기법이 예측 성능을 안정화하는 데 효과적으로 작용하였다. 실제로 PCA 미적용 상태에서는 정규화 회귀 모델들이 선형 회귀 대비 더 나은 성능을 보였다.

반면 PCA를 적용한 이후에는 변수 간 상관성이 제거되고 입력 공간이 직교화되면서, 선형 회귀 모델만으로도 안정적인 계수 추정이 가능해졌다. 이로 인해 추가적인 정규화의 필요성이 감소하였으며, 일부 경우에는 정규화로 인한 수축 효과가 오히려 성능 저하로 이어졌다.

종합적으로 볼 때, 본 연구에서는 모델의 복잡도보다 전처리 단계에서의 PCA 적용이 예측 성능 향상에 핵심적인 역할을 수행하였다. 이에 따라 RMSE를 기준으로 PCA를 적용한 선형 회귀 모델을 최종 모델로 선정하였다.

PCA를 적용한 선형 회귀 모형의 결정계수(R^2)는 0.793으로, 전체 수확량 변동의 약 79%를 설명하는 것으로 나타났다. 수정 결정계수 또한 0.782로 높게 유지되어, 주성분 개수를 고려하더라도 모형의 설명력이 충분함을 확인하였다. F-검정 결과 모형 전체는 통계적으로 매우 유의하였으며($p < 0.05$), 다수의 주성분이 수확량과 유의한 관계를 가지는 것으로 분석되었다. 또한 PCA 적용으로 다중공선성 문제가 효과적으로 완화된 것으로 판단된다.

-입력 변수의 기여도 분석

[Feature Importance Top5]

PC		ORIGINAL	
PC1	0.056192	EVI9	0.725867
PC3	0.046721	EVI3	0.615390
PC5	0.023964	EVI8	0.612626
PC2	0.022762	EVI5	0.611985
PC12	0.004176	VOD6	0.604573

- 최종 선정된 PCA 적용 선형 회귀 모델을 대상으로 입력 변수의 기여도를 분석하였다. PCA 적용 모델의 경우 회귀계수는 주성분(PC) 공간에서 추정되므로, 먼저 주성분 중요도를 확인한 뒤 이를 원 변수 공간으로 환산하여 해석하였다.

- 주성분 중요도 분석 결과, PC1과 PC3이 가장 큰 기여도를 차지하였으며, 이후 PC5, PC2 순으로 영향력이 감소하는 경향을 보였다. 이는 수확량 변동의 상당 부분이 소수의 주요 주성분에 의해 설명되고 있음을 의미하며, PC12 이후의 주성분들은 기여도가 매우 낮아, 예측 성능에 미치는 영향이 제한적인 것으로 나타났다.

- 주성분을 원 변수 공간으로 환산한 결과, 식생 지수(EVI 계열)가 가장 높은 기여도를 보였다. 특히 EVI9, EVI3, EVI8, EVI5, EVI11 등이 상위 변수로 반복적으로 등장하여, 생육 중·후반 시기의 식생 상태가 옥수수 수확량 예측에 핵심적인 역할을 수행함을 확인하였다.

또한 강수량(PRCP) 변수(PRCP6, PRCP5, PRCP1)와 식생 수분 지표(VOD) 변수(VOD6, VOD1) 역시 높은 기여도를 보여, 수확량이 단순한 생육 상태뿐만 아니라 생육 기간 중 수분 공급 조건과 밀접하게 연관되어 있음을 시사한다.

이러한 경향은 PCA 적용 여부 및 모델 종류와 관계없이 공통적으로 관찰되었으며, 다른 회귀 모델에서도 EVI 계열 변수가 가장 중요한 입력 변수로 나타났다. 이는 위성 기반 식생 지수가 county 단위 옥수수 수확량을 설명하는 데 가장 직접적이고 안정적인 정보를 제공함을 의미한다.

3. 분류


3.1. 사용 자료

- 본 연구에서는 토지 피복 분류를 위해 제공된 Classification_training.csv와 Classification_test.csv 자료를 사용하였다. 과제 조건에 따라 전체 학습 자료 중 5%를 무작위로 추출하여 학습 데이터로 구성하였으며, test 자료는 모델의 일반화 성능 평가에 사용하였다. 분류 대상 클래스는 LC(Land Cover)로 정의되며, 각 픽셀의 토지 피복 유형을 나타내는 다중 클래스 변수이다.

- 입력 변수는 총 9개로 구성되어 있다. ATM1부터 ATM6은 대기 또는 광학 관측을 통해 얻어진 변수로, 지표 반사 특성 및 환경 조건의 차이를 반영한다. L_HH, L_HV, L_VV는 레이더 산란 계수로, 동일 편파(HH, VV) 및 교차 편파(HV)에 대한 산란 강도를 나타내며, 표면 거칠기, 식생 구조, 수분 상태 등에 민감하게 반응한다. 이러한 광학 및 레이더 변수들은 물리적 의미와 반응 특성이 상이하여, 토지 피복 유형에 따라 복합적인 패턴을 형성한다.

- 학습 자료와 test 자료의 클래스 분포를 비교한 결과, 일부 클래스에서 샘플 비율 차이가 존재하여 학습 데이터와 test 데이터 간 분포 불일치가 관찰되었다. 이러한 분포 차이는 모델 학습 과정에서 충분히 반영되지 않은 패턴이 test 자료에 포함될 가능성을 의미하며, 예측 오차 증가의 요인으로 작용할 수 있다.

- 또한 입력 변수 간 상관관계를 분석한 결과, ATM 계열 변수들, L 계열 변수들 사이에서 매우 높은 양의 상관관계가 확인되었다. 이는 동일하거나 유사한 정보를 중복적으로 포함하고 있을 가능성을 시사하며, 모델 학습 시 변수 간 의존성이 성능과 해석에 영향을 미칠 수 있음을 의미한다. 따라서 본 연구에서는 이러한 변수 간 상관 구조와 자료 분포 특성을 고려하여 이후 분류 모델을 적용하고 성능을 비교·분석하였다.



3.2. 분류 모델

본 연구에서는 토지 피복 유형과 같이 다중 클래스 반응 변수를 분류하기 위해 SoftMax 분류 모델과 Random Forest 분류 모델을 적용하였다. 분류 분석은 입력 변수 공간에서 각 클래스에 속할 확률 또는 결정 규칙을 학습하여, 새로운 관측값의 범주를 예측하는 기법이다. 본 절에서는 본 연구에서 사용한 주요 분류 모델의 이론적 배경을 간략히 설명한다.

- SoftMax 분류

이 모델은 다중 클래스 분류 문제를 위해 확장된 로지스틱 회귀 모델이다. 각 클래스에 대해 선형 결합 형태의 점수를 계산한 후, 이를 Softmax 함수에 입력하여 클래스별 확률을 산출한다. 최종 예측 클래스는 가장 높은 확률을 갖는 클래스로 결정된다. Softmax 분류는 모델 구조가 비교적 단순하고 확률적 해석이 가능하다는 장점이 있으나, 입력 변수와 클래스 간의 관계를 선형 결정 경계로 가정하기 때문에 복잡한 비선형 패턴을 충분히 표현하는 데에는 한계가 있다.

- Random Forest 분류

이 모델은 다수의 의사결정나무(Decision Tree)를 결합한 앙상블 학습 기반의 분류 모델이다. 각 트리는 학습 데이터의 부트스트랩 샘플을 사용하여 생성되며, 분할 시 전체 변수 중 일부만을 무작위로 선택함으로써 트리 간 다양성을 확보한다. 최종 분류 결과는 개별 트리들의 예측 결과에 대한 다수결 방식으로 결정된다. Random Forest는 변수 간 비선형 관계와 복잡한 상호작용을 효과적으로 학습할 수 있으며, 변수 스케일에 민감하지 않고 과적합에 비교적 강건한 특성을 가진다.

3.3. 자료 처리 절차

- 데이터 로드

본 연구에서는 토지 피복 분류를 위해 Classification_training.csv와 Classification_test.csv 자료를 사용하였다. 과제 조건에 따라 전체 학습 자료 중 5%를 무작위로 추출하여 학습 데이터로 구성하였으며, 테스트 자료는 모델의 일반화 성능 평가에 사용하였다. 무작위 추출 과정에서는 재현성을 확보하기 위해 고정된 난수 시드를 적용하였다.

종속 변수는 토지 피복 유형을 나타내는 LC로 설정하였으며, 입력 변수는 ATM1-ATM6과 레이더 산란 계수인 L_HH, L_HV, L_VV의 총 9개 변수로 구성하였다. 학습 데이터와 테스트 데이터에 동일한 입력 변수를 적용하여 독립변수 행렬을 구성하였으며, 이후 분류 모델 학습 및 성능 비교 분석을 수행하였다.

```
train_full = pd.read_csv('../data/Classification_training.csv')  
  
test_data = pd.read_csv('../data/Classification_test.csv')
```



```
train_sampled = train_full.sample(frac=0.05, random_state=42)

y_train = train_sampled['LC']
y_test = test_data['LC']

features = ['ATM1', 'ATM2', 'ATM3', 'ATM4', 'ATM5', 'ATM6', 'L_HH', 'L_HV', 'L_VV']

X_train = train_sampled[features]
X_test = test_data[features]
```

-SoftMax Model 적용

토지 피복 분류를 위해 다중 클래스 분류가 가능한 Softmax 분류 모델을 적용하였다. Softmax 분류는 로지스틱 회귀를 확장한 방식으로, 각 클래스에 속할 확률을 동시에 추정하여 가장 높은 확률을 갖는 클래스로 분류한다.

학습 단계에서는 선택된 입력 변수 집합을 사용하여 모델을 학습시킨 후, 독립적인 테스트 자료에 대해 예측을 수행하였다. 모델 성능 평가는 전체 정확도(Accuracy), 분류 보고서(classification report), 그리고 혼동행렬(confusion matrix)을 통해 수행하였다. 이를 통해 각 토지 피복 클래스별 분류 성능과 오분류 양상을 함께 분석하였다.

```
def run_softmax(X_train, y_train, X_test, y_test, feature_name):

    print(f"\n===== Softmax | {feature_name} =====")

    model = LogisticRegression(

        multi_class='multinomial',

        solver='lbfgs',

        max_iter=1000

    )
```

```
model.fit(X_train, y_train)

y_pred = model.predict(X_test)

print("Accuracy:", accuracy_score(y_test, y_pred))

print(classification_report(y_test, y_pred))

print(confusion_matrix(y_test, y_pred))
```

-Random Forest 모델 적용

본 연구에서는 토지 피복 분류를 위해 Random Forest 분류 모델을 추가적으로 적용하였다. Random Forest는 다수의 결정트리를 앙상블 방식으로 결합한 비선형 분류 기법으로, 각 트리는 학습 데이터의 일부와 입력 변수의 일부를 무작위로 선택하여 생성된다. 이를 통해 단일 결정트리의 과적합 문제를 완화하고, 보다 안정적인 분류 성능을 확보할 수 있다.

모델 학습 과정에서는 트리의 개수(n_estimators)와 최대 깊이(max_depth)를 주요 하이퍼파라미터로 설정하고, Grid Search 기반의 교차 검증을 통해 최적의 조합을 탐색하였다. 학습된 최적 모델은 테스트 자료에 적용하여 예측을 수행하였으며, 성능 평가는 정확도(Accuracy), 분류 보고서, 혼동행렬을 통해 이루어졌다. 이를 통해 변수 조합에 따른 분류 성능 변화와 클래스별 예측 특성을 함께 분석하였다.

```
def run_random_forest(X_train, y_train, X_test, y_test, feature_name):

    print(f"\n===== Random Forest | {feature_name} =====")

    rf = RandomForestClassifier(

        random_state=42,

        class_weight='balanced'

    )

    param_grid = {

        'n_estimators': [100, 200, 300, 400, 500, 600],
```

```
        'max_depth': [3, 5, 7, 10, 20, None]
    }

    grid = GridSearchCV(
        rf,
        param_grid,
        cv=3,
        scoring='accuracy',
        n_jobs=-1
    )

    grid.fit(X_train, y_train)

    best_model = grid.best_estimator_

    print("Best parameters:", grid.best_params_)

    y_pred = best_model.predict(X_test)

    print("Accuracy:", accuracy_score(y_test, y_pred))

    print(classification_report(y_test, y_pred))

    print(confusion_matrix(y_test, y_pred))


    return best_model
```

3.4. 결과

3.4.1. 최적 모델 선정

SoftMax ATM + L Accuracy: 0.6435124508519003

	precision	recall	f1-score	support
1	0.98	0.82	0.89	197
2	0.53	0.82	0.64	190
3	0.54	0.53	0.53	97
4	0.77	0.36	0.49	181
5	0.46	0.59	0.52	98




본 연구에서는 입력 변수 조합과 분류 모델에 따른 성능을 Accuracy 기준으로 비교한 결과, ATM과 L 변수를 함께 사용한 Softmax 모델이 가장 우수한 분류 성능을 보였다. 해당 모델은 전체 정확도 0.64로, ATM 단독 또는 L 단독을 사용한 경우보다 명확한 성능 향상을 나타냈다. 이는 광학 영상 변수와 레이더 변수의 결합이 서로 보완적으로 작용하여 토지 피복 분류에 필요한 정보를 보다 충분히 제공했기 때문으로 판단된다.

또한 Softmax 모델은 모든 변수 조합에서 Random Forest 모델보다 일관되게 높은 정확도를 기록하였다. 이는 학습 데이터가 전체의 5%로 제한된 조건에서, 비교적 단순한 구조의 Softmax 모델이 데이터 분포를 안정적으로 학습한 반면, Random Forest 모델은 충분한 분기 규칙을 형성하지 못했기 때문으로 해석된다.

종합적으로, 본 연구에서는 변수 결합 효과와 모델 안정성 측면에서 가장 우수한 성능을 보인 ATM+L 기반 Softmax 모델을 최적 모델로 선정하였다.

3.4.2. 오차 행렬 기반 조합에 따른 분류 정확도 분석



Softmax 분류 모델의 오차 행렬을 분석한 결과, 입력 변수 조합에 따라 클래스별 분류 성능과 오분류 양상이 뚜렷하게 달라지는 것이 확인되었다.

먼저 **ATM 변수(광학 밴드)만 사용한 경우**, Sugar beets(클래스 1)에 대한 분류 정확도가 매우 높게 나타났다. 이는 Blue-Red 영역에서의 엽록소 흡수 특성과 NIR, SWIR 밴드에서의 높은 반사 특성이 사탕무의 넓은 잎과 높은 생체량을 잘 반영하기 때문으로 해석된다. 반면, Bare soil(클래스 3)과 Potato(클래스 4), Carrot(클래스 5) 간에는 분광 반사 특성이 유사하거나 데이터의 분포에 차

이가 존재해 오분류가 다수 발생하였다.

L-밴드 변수만 사용한 경우, Bare soil(클래스 3)과 Potato(클래스 4)의 구분이 상대적으로 개선되는 양상이 관찰되었다. 이는 L-밴드 레이더 신호가 지표면 거칠기, 작물 이랑 구조, 토양 수분 상태에 민감하게 반응하기 때문으로 판단된다. 특히 Bare soil은 낮은 산란 강도를 보이는 반면, Potato는 이랑 구조와 식생 잔존으로 인해 HH 및 HV 편파에서 서로 다른 산란 특성을 나타내어 분류에 기여한 것으로 해석된다.

ATM과 L 변수를 결합한 경우, 전반적인 분류 성능이 가장 안정적으로 나타났으며, 오차 행렬에서도 대부분의 클래스에서 대각 성분이 증가하였다. 광학 변수는 식생의 분광적·화학적 특성을, 레이더 변수는 구조적·물리적 특성을 보완적으로 제공함으로써 토지 피복 유형 간 구분력을 향상시킨 것으로 판단된다. 특히 각각의 단점이었던 Sugar beets와 Potato간의 오분류, studdel과 Potato 간의 오분류가 감소하는 경향이 확인되었다.

	precision	recall	f1-score	support
1	0.98	0.82	0.89	197
2	0.53	0.82	0.64	190
3	0.54	0.53	0.53	97
4	0.77	0.36	0.49	181
5	0.46	0.59	0.52	98

다만, ATM과 L 변수를 결합한 Softmax 모델의 정확도를 분석한 결과, 전반적인 분류 성능은 향상되었으나 ****클래스 2(Stubble), 3(Bare soil), 5(Carrot)****에서 상대적으로 오분류가 빈번하게 발생하였다.

먼저 ****클래스 3(Bare soil)****의 경우, 학습 데이터 내 표본 수가 다른 클래스에 비해 상대적으로 적어 모델이 해당 클래스의 분광적 변동성을 충분히 학습하지 못한 것으로 판단된다. 이로 인해 Bare soil은 분광 특성이 유사한 Stubble 또는 일부 작물 클래스로 오분류되는 경향을 보였다.

****클래스 2(Stubble)****는 식생과 비식생의 중간적 특성을 가지는 클래스이다. 광학 영상에서는 잔존 식생으로 인해 완전한 토양과 구분이 어려우며, L-밴드 레이더에서는 수확 후 남은 구조로 인해 체적 산란이 발생한다. 이러한 특성으로 인해 Stubble은 Bare soil 및 일부 작물 클래스와 특성 공간에서 중첩되며, Softmax 모델에서 오분류의 중심 역할을 한 것으로 해석된다.

****클래스 5(Carrot)****는 지상부 식생 구조가 상대적으로 작고 토양 노출 비율이 높아, 광학 및 레이더 변수 모두에서 Bare soil 또는 Stubble과 유사한 반응을 보인다. 이로 인해 Carrot은 Stubble 또는 Potato로 예측되는 사례가 다수 발생하였다.

종합적으로, 클래스 2·3·5에서의 분류 성능 저하는 **학습 데이터 분포의 불균형과 분광·산란 특성의 중첩**에 기인한 것으로 판단된다.

